

# You Only Look Once

Unified, Real-Time Object Detection

발표자 한나경

### **Contents**

- Part 0. Object Detection
- Part 1. Abstract
- Part 2. Introduction
- Part 3. Unified Detection


Part 3.1. Network Design

Part 3.2. Training

Part 3.3. Inference

- Part 4. Experiments
- Part 5. Limitations of YOLO


### **Object Detection**



### **Object Detection**

### 2-stage object detector


- Localization -> Classification 순차적으로 진행
- Object가 있을 만한 위치를 제안하는 Region Proposal 과정을 거침
- 정확도 높음, 속도 느림
- Fast R-CNN



etc.

### 1-stage object detector

- Localization, Classification 동시에 수행
- 이미지 내의 모든 위치를 Object의 잠재 영역으로 봄
- 정확도 낮음, 속도 빠름
- YOLO v1



# You Only Look Once

Unified, Real-Time Object Detection

1-stage object detector 방식 사용

Localization & Classification 단계 단일화

속도 측면에서 개선된 모델


### Introduction


### **Advantage**

- 1. 속도 향상 : Object detection을 regression problem으로 관점 전환 -> 한번에 처리하는 end-to-end 구조
- 2. Background error 감소 : 학습 과정에서 이미지 전체를 보고 예측하므로 Background error 감소
- 3. 다른 도메인에서도 Object detection 성능 우수

#### **Disadvantage**


1. 정확도 감소: 빠르게 객체를 탐지할 수 있다는 장점이 있지만 정확성이 떨어짐, 특히 작은 물체에 대한 정확도 감소, 속도와 정확도 반비례





**Figure 1: The YOLO Detection System.** Processing images with YOLO is simple and straightforward. Our system (1) resizes the input image to  $448 \times 448$ , (2) runs a single convolutional network on the image, and (3) thresholds the resulting detections by the model's confidence.

### **Unified Detection**




**Figure 2: The Model.** Our system models detection as a regression problem. It divides the image into an  $S \times S$  grid and for each grid cell predicts B bounding boxes, confidence for those boxes, and C class probabilities. These predictions are encoded as an  $S \times S \times (B*5+C)$  tensor.

For evaluating YOLO on PASCAL VOC, we use S=7, B=2. PASCAL VOC has 20 labelled classes so C=20. Our final prediction is a  $7\times7\times30$  tensor.


- Region proposal, feature extraction, classification, bbox regression -> 1-stage detection로 통합
- 이미지 전체로부터 얻은 feature를 활용하여 bbox 예측 & 모든 클래스에 대한 확률 계산
- SxS grid cell -> each grid cell, B bbox prediction + confidence & class probabilities -> S x S x (B \* 5 + C)

### **Unified Detection**




<sup>\*</sup> IoU: Intersection over Union의 약자로 실제 객체의 bbox와 예측한 bbox가 얼마나 일치하는지를 나타낸다.

# Part 3.1 Network Design



- 20 conv layer : pretrained with 1000-class ImageNet (input image : 224 x 224)
- 4 conv layer + 2 fc layer : detection 수행 (input image : 448 x 448)
- 중간에 1 x 1 reduction layer로 연산량 감소
- 최종 Output : class의 확률 값, bbox의 위치 정보


# Part 3.1 Network Design



$$\phi(x) = egin{cases} x, & ext{if } x > 0 & ext{pn T막 계층 제외 leaky ReLU} \ 0.1x, & ext{otherwise} & ext{pn T막 계층 : linear activation function h(x) = cx} \ & ext{leaky ReLU} \end{cases}$$

# Part 3.2 Training

특정 object에 responsible한 cell i는 GT box의 중심이 위치하는 cell로 할당






GT box내에 존재하는 Object에 responsible한 cell

# Part 3.2 Training

특정 object에 responsible한 cell i는 GT box의 중심이 위치하는 cell로 할당 YOLO는 여러 bbox를 예측하지만, 학습단계에서는  $IOU_{pred}^{truth}$  가장 높은 bbox 1개만 사용 ->  $\mathbb{1}_{ij}^{obj}$  로 cell i에서 responsible한 j번째 bbox를 표시하여 loss function에 반영





# Part 3.2 Training

#### loss function:

$$\begin{split} \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{obj}} \left[ (x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] \\ + \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{obj}} \left[ \left( \sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left( \sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right] \\ + \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{obj}} \left( C_i - \hat{C}_i \right)^2 \\ + \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{noobj}} \left( C_i - \hat{C}_i \right)^2 \\ + \sum_{i=0}^{S^2} \mathbb{1}_{i}^{\text{obj}} \sum_{c \in \text{classes}} (p_i(c) - \hat{p}_i(c))^2 \end{split}$$

$$\mathbb{1}_{ij}^{\text{obj}}$$
 Cell i의 j번째 bbox가 responsible (highest IoU), (1 or 0)


 $\mathbb{I}_i^{\text{obj}}$  Cell i에 object 존재 여부 (1 or 0)

 $\lambda_{\rm coord}$  5, bbox coordinates loss

 $\lambda_{
m noobj}$  0.5, 객체 없는 박스

- 1) Object 존재하는 cell i의 j번째 bbox predictor에 대해 x, y loss
- 2) Object 존재하는 cell i의 j번째 bbox predictor에 대해 w, h loss
- 3) Object 존재하는 cell i의 j번째 bbox predictor에 대해 confidence score의 loss
- 4) Object 존재하지 않는 cell i의 j번째 bbox predictor에 대해 confidence score의 loss
- 5) Object 존재하는 cell i의 conditional class probability loss

# Part 3.3 Inference



**Figure 2:** The Model. Our system models detection as a regression problem. It divides the image into an  $S \times S$  grid and for each grid cell predicts B bounding boxes, confidence for those boxes, and C class probabilities. These predictions are encoded as an  $S \times S \times (B*5+C)$  tensor.

For evaluating YOLO on PASCAL VOC, we use S=7, B=2. PASCAL VOC has 20 labelled classes so C=20. Our final prediction is a  $7\times 7\times 30$  tensor.

- 7 x 7 x 2개 bbox 예측, 각 bbox마다 class probability 계산
- Non-Maximum Suppression(NMS) 적용
- -> 다중검출 개선 : 하나의 object에 대해 여러 cell이 검출하는 문제 개선
- mAP 2-3% 향상

### **Experiments**

#### 4.1. Comparison to Other Real-Time Systems


Real-Time Detectors	Train	mAP	<b>FPS</b>
100Hz DPM [31]	2007	16.0	100
30Hz DPM [31]	2007	26.1	30
Fast YOLO	2007+2012	52.7	155
YOLO	2007+2012	63.4	45
Less Than Real-Time			
Fastest DPM [38]	2007	30.4	15
R-CNN Minus R [20]	2007	53.5	6
Fast R-CNN [14]	2007+2012	70.0	0.5
Faster R-CNN VGG-16[28]	2007+2012	73.2	7
Faster R-CNN ZF [28]	2007+2012	62.1	18
YOLO VGG-16	2007+2012	66.4	21

mAP: mean average precision -> 정확도

FPS: Frame Per Second -> 속도

다른 Real-Time Detectors에 비해 정확도 높음, 속도 빠름 R-CNN 계열은 정확도 높음 but 속도 느림

### 4.2. VOC 2007 Error Analysis4.3. Combining Fast R-CNN and YOLO



	mAP	Combined	Gain
Fast R-CNN	71.8	-	-
Fast R-CNN (2007 data)	66.9	72.4	.6
Fast R-CNN (VGG-M)	59.2	72.4	.6
Fast R-CNN (CaffeNet)	57.1	72.1	.3
YOLO	63.4	75.0	3.2

백그라운드 error의 감소

Fast R-CNN과 YOLO의 결합시 mAP이 3.2% 향상

## **Experiments**

#### 4.4. VOC 2012 Results

VOC 2012 test	mAP	aero	bike	bird	boat	bottle	bus	car	cat	chair	cow	table	dog	horse	mbike	person	nplant	sheep	sofa	train	tv
MR_CNN_MORE_DATA [11]	73.9	85.5	82.9	76.6	57.8	62.7	79.4	77.2	86.6	55.0	79.1	62,2	87.0	83.4	84.7	78.9	45.3	73.4	65.8	80.3	74.0
HyperNet_VGG	71.4	84.2	78.5	73.6	55.6	53.7	78.7	79.8	87.7	49.6	74.9	52.1	86.0	81.7	83.3	81.8	48.6	73.5	59.4	79.9	65.7
HyperNet_SP	71.3	84.1	78.3	73.3	55.5	53.6	78.6	79.6	87.5	49.5	74.9	52.1	85.6	81.6	83.2	81.6	48.4	73.2	59.3	79.7	65.6
Fast R-CNN + YOLO	70.7	83.4	78.5	73.5	55.8	43.4	79.1	73.1	89.4	49.4	75.5	57.0	87.5	80.9	81.0	74.7	41.8	71.5	68.5	82.1	67.2
MR_CNN_S_CNN [11]	70.7	85.0	79.6	71.5	55.3	57.7	76.0	73.9	84.6	50.5	74.3	61.7	85.5	79.9	81.7	76.4	41.0	69.0	61.2	77.7	72.1
Faster R-CNN [28]	70.4	84.9	79.8	74.3	53.9	49.8	77.5	75.9	88.5	45.6	77.1	55.3	86.9	81.7	80.9	79.6	40.1	72.6	60.9	81.2	61.5
DEEP_ENS_COCO	70.1	84.0	79.4	71.6	51.9	51.1	74.1	72.1	88.6	48.3	73.4	57.8	86.1	80.0	80.7	70.4	46.6	69.6	68.8	75.9	71.4
NoC [29]	68.8	82.8	79.0	71.6	52.3	53.7	74.1	69.0	84.9	46.9	74.3	53.1	85.0	81.3	79.5	72.2	38.9	72.4	59.5	76.7	68.1
Fast R-CNN [14]	68.4	82.3	78.4	70.8	52.3	38.7	77.8	71.6	89.3	44.2	73.0	55.0	87.5	80.5	80.8	72.0	35.1	68.3	65.7	80.4	64.2
UMICH_FGS_STRUCT	66.4	82.9	76.1	64.1	44.6	49.4	70.3	71.2	84.6	42.7	68.6	55.8	82.7	77.1	79.9	68.7	41.4	69.0	60.0	72.0	66.2
NUS_NIN_C2000 [7]	63.8	80.2	73.8	61.9	43.7	43.0	70.3	67.6	80.7	41.9	69.7	51.7	78.2	75.2	76.9	65.1	38.6	68.3	58.0	68.7	63.3
BabyLearning [7]	63.2	78.0	74.2	61.3	45.7	42.7	68.2	66.8	80.2	40.6	70.0	49.8	79.0	74.5	77.9	64.0	35.3	67.9	55.7	68.7	62.6
NUS_NIN	62.4	77.9	73.1	62.6	39.5	43.3	69.1	66.4	78.9	39.1	68.1	50.0	77.2	71.3	76.1	64.7	38.4	66.9	56.2	66.9	62.7
R-CNN VGG BB [13]	62.4	79.6	72.7	61.9	41.2	41.9	65.9	66.4	84.6	38.5	67.2	46.7	82.0	74.8	76.0	65.2	35.6	65.4	54.2	67.4	60.3
R-CNN VGG [13]	59.2	76.8	70.9	56.6	37.5	36.9	62.9	63.6	81.1	35.7	64.3	43.9	80.4	71.6	74.0	60.0	30.8	63.4	52.0	63.5	58.7
YOLO	57.9	77.0	67.2	57.7	38.3	22.7	68.3	55.9	81.4	36.2	60.8	48.5	77.2	72.3	71.3	63.5	28.9	52.2	54.8	73.9	50.8
Feature Edit [33]	56.3	74.6	69.1	54.4	39.1	33.1	65.2	62.7	69.7	30.8	56.0	44.6	70.0	64.4	71.1	60.2	33.3	61.3	46.4	61.7	57.8
R-CNN BB [13]	53.3	71.8	65.8	52.0	34.1	32.6	59.6	60.0	69.8	27.6	52.0	41.7	69.6	61.3	68.3	57.8	29.6	57.8	40.9	59.3	54.1
SDS [16]	50.7	69.7	58.4	48.5	28.3	28.8	61.3	57.5	70.8	24.1	50.7	35.9	64.9	59.1	65.8	57.1	26.0	58.8	38.6	58.9	50.7
R-CNN [13]	49.6	68.1	63.8	46.1	29.4	27.9	56.6	57.0	65.9	26.5	48.7	39.5	66.2	57.3	65.4	53.2	26.2	54.5	38.1	50.6	51.6


YOLO 모델의 경우 57.9%의 mAP으로 정확도 낮은 편

But Fast R-CNN + YOLO의 경우에는 70.7%로 향상된 정확도를 볼 수 있음

### **Experiments**

#### 4.5. Generalizability: Person Detection in Artwork





	VOC 2007	Pi	casso	People-Art
	AP	AP	Best $F_1$	AP
YOLO	59.2	53.3	0.590	45
R-CNN	54.2	10.4	0.226	26
DPM	43.2	37.8	0.458	32
Poselets [2]	36.5	17.8	0.271	
D&T [4]	-	1.9	0.051	

(a) Picasso Dataset precision-recall curves.

(b) Quantitative results on the VOC 2007, Picasso, and People-Art Datasets. The Picasso Dataset evaluates on both AP and best  $F_1$  score.

학습 데이터셋과 다른 분포를 가진 Picasso Dateset과 People-Art Dataset 이용하여 테스트 진행

다른 모델들은 VOC2007에서의 정확도보다 현저히 떨어지지만, YOLO는 유사한 정확도를 가짐

-> YOLO는 객체의 일반적인 특징(feature)을 학습하기 때문

### **Limitations of YOLO**

- 1. 작은 물체에 대한 검출 부정확 가능성 : object가 작을수록 bbox 간 IoU 값의 차이가 작아 object가 큰 박스보다 predictor가 작은 차이로 결정됨
- 2. 하나의 cell이 하나의 물체만 검출하므로 2개 이상의 객체가 겹쳐져 있다면 검출하기 어려움
- 3. 새로운 비율의 물체에 대해서는 검출이 어려움 : data에서 bounding box를 예측하는 것을 학습하기 때문
- 4. bbox의 크기와 상관없이 bbox의 loss에 동일한 가중치를 둠 : 크기가 작은 bbox의 경우 위치가 조금이라도 달라진다면 loU 변화가 크므로 성능에 큰 영향을 줄 수 있음



# 감사합니다